

Análisis de Sentimientos Espaciotemporal en Redes Sociales para Evaluación de Riesgo en Desastres Naturales

Jayan Michael Caceres Cuba
Universidad Naional de San Agustin
Arequipa, Peru
jcacerescu@unsa.edu.pe

Abstract—Las redes sociales desempeñan un papel fundamental en el análisis de las emociones reales de las personas después y durante un desastre. El análisis de sentimientos es un método para detectar patrones a partir de las emociones y la retroalimentación del usuario. El objetivo principal del trabajo propuesto es realizar un análisis de sentimientos de los tuits sobre un contexto de desastre específico para una ubicación específica en diferentes intervalos de tiempo. El modelo ayuda al gobierno a tomar medidas preventivas para gestionar los efectos posteriores al desastre en un lugar.

Index Terms—Análisis de sentimientos, Desastres naturales, Redes sociales, Geolocalización, Aprendizaje profundo, Procesamiento de lenguaje natural Evaluación de riesgo

I. INTRODUCTION

En el mundo digital actual, hay un gran aumento en la cantidad de personas que comparten sus opiniones en plataformas de redes sociales como Twitter ahora llamado X, Facebook, Instagram, etc. Donde suelen expresar sus opiniones sobre diversos eventos, como deportes, desastres, política, películas, negocios, etc., en estas plataformas las opiniones compartida en estas redes sociales incluye emociones y sentimientos sobre un evento o persona en particular. Incluso en plataformas de comercio electrónico como Amazon, las personas comparten sus experiencias y opiniones sobre la calidad de los productos que compran. [6] [7] Las personas también tienden a compartir sus opiniones sobre las películas que ven en plataformas como IMDB, Rotten Tomatoes, etc. Las opiniones o sentimientos compartidos por las personas en plataformas en línea influyen en la opinión de otras personas sobre una película, conflictos regionales, negocios, películas, productos y atención médica, [8]. El análisis de sentimientos es una tecnología que permite categorizar las opiniones, opiniones y reseñas compartidas por las personas en forma de texto, emojis, etc., como negativas, positivas o neutrales mediante el procesamiento del lenguaje natural.

Actualmente con los avances en inteligencia artificial, análisis de big data, aprendizaje automático, 11-13 algoritmos meta-heurísticos 14-16 y redes neuronales profundas, se ha vuelto aún más conveniente extraer patrones y tendencias ocultos mediante la integración de estas técnicas con el análisis de sentimientos. Estas técnicas mejoraron la fiabilidad de los resultados mediante el análisis de sentimientos. pero hoy en día, no basta con medir los sentimientos positivos y negativos.

Las partes interesadas también deben evaluar o comprender las razones por las que las personas tienen opiniones neutrales y tomar las medidas necesarias para influir en ellas. Los desastres naturales, como inundaciones, tsunamis, tornados, ciclones, incendios forestales, etc., ocurren con frecuencia en nuestro planeta, afectando a miles de personas, ganado y fauna silvestre, además de causar enormes daños a las propiedades. Es imposible detener o prevenir estos desastres naturales. Sin embargo, al obtener suficiente información, se pueden minimizar sus efectos. La principal motivación de este trabajo es extraer los patrones/sentimientos ocultos de los sentimientos, publicaciones, tuits, etc., de las personas en plataformas en línea durante desastres naturales. Esto permitirá a las partes interesadas, como gobiernos, ONG, etc., actuar de manera oportuna. Estudios previos de análisis de tweets se enfocaron [1] en identificar patrones de atención y emociones en distintas regiones y fases posteriores al desastre o [2] como se propagan y transforman las emociones colectivas, [2] o clasificadores de texto que permitan extraer y analizar características espacio-temporales de la información publicada en Micro-blogging durante desastres. Mientras muchos estudios de la comunidad se centran en el análisis de sentimientos sin tener en cuenta la simultaneidad del evento, la ubicación y el tiempo. este modelo evalúa sentimientos en función del lugar y la etapa del evento (durante o después del desastre). Esto permite que se pueda actuar lo más oportunamente posible frente a un evento y una evaluación del riesgo mucho más contextual.

II. TRABAJOS RELACIONADOS

Esta sección aborda el estudio del análisis de sentimientos basado en la satisfacción del cliente y la gestión de desastres. Recientemente, la comunidad investigadora ha mostrado un gran interés en aplicar numerosas estrategias de aprendizaje profundo e inteligencia artificial a la evaluación de riesgos de un evento.

Desde la perspectiva de los métodos utilizados, se pueden agrupar en enfoques basados en diccionarios (lexicon-based) y en aprendizaje automático (ML – machine learning). En los primeros, se elaboran tesauros de términos con polaridad pre-definida —por ejemplo, Opinion Finder o SentiWordNet para textos generales—, y en algunos casos se adaptan lexicones

a dominios específicos como el turismo [4]. Estos métodos ofrecen rapidez de implementación y claridad interpretativa, pero adolecen de rigidez ante variaciones de contexto, ironía o lenguaje coloquial, y no capturan la semántica implícita en mensajes cortos y ruidosos.

En el ámbito geoespacial, estudios sobre la propagación de información tras terremotos o conflictos han empleado minería de clusters y visualizaciones con cubos espacio-tiempo, Sankey o matrices de co-ocurrencia [11] [12]. Aportan una visión dinámica del impacto emocional, pero no integran de forma automática el análisis profundo de sentimiento ni generan métricas consolidadas (p. ej., índices de riesgo emocional por zona y momento), lo que dificulta su aplicación en tiempo real para la toma de decisiones.

Un estudio relevante compara las respuestas de la opinión pública ante los terremotos de Yangbi (M6.4) y Maduo (M7.4), empleando un modelo de agrupación temática (Latent Dirichlet Allocation, LDA) y un análisis emocional basado en diccionarios léxicos. El objetivo es identificar patrones de atención y emociones en distintas regiones y fases posteriores al desastre [1].

Otro trabajo examina la evolución del sentimiento público y la dinámica espacio-temporal en torno al colapso de una vivienda autoconstruida en Changsha, China. Utilizando datos de comentarios extraídos de Sina Weibo, se analiza cómo se propagan y transforman las emociones colectivas ante un evento crítico de carácter urbano [2].

En un enfoque similar, se propone un método basado en clasificación de texto para extraer y analizar características espacio-temporales de mensajes publicados en Microblog durante desastres provocados por lluvias e inundaciones. Esta metodología busca contribuir a la toma de decisiones en la gestión de emergencias y operaciones de rescate [3].

Adicionalmente, se ha realizado una revisión sistemática de métodos de análisis de sentimientos aplicados al turismo, destacando cómo el uso de Big Data permite avanzar en la comprensión de emociones y opiniones expresadas en redes sociales y reseñas de viajeros. El estudio compara diferentes enfoques, conjuntos de datos y métricas de evaluación [4].

Por último, se analiza el uso de técnicas de aprendizaje profundo en el análisis de sentimientos basado en aspectos, presentando una visión general de los modelos implementados y sus aplicaciones potenciales para investigaciones futuras en el reconocimiento automático de emociones y opiniones específicas [5].

III. OVERVIEW

A. Descripción y preprocesamiento de los datos

Es conjunto de datos "Social media disaster tweets-DFE" de Kaggle, disponible públicamente en un archivo separado por comas. Contiene un total de 629 365 000 registros, que corresponden a tuits recopilados en diversas ubicaciones del entorno global durante el año 2015, a lo largo de todos los meses y en diferentes períodos. El conjunto de datos consta de 13 columnas, que se describen en la Tabla 5. De estas, las columnas que influyen en nuestro análisis son las

de choose-one, keyword, location, y text. Las demás columnas contienen información general, que no requerimos para clasificarlas como relevantes o no relevantes para el desastre. Consideramos los tuits relevantes como positivos y los demás como negativos. Existe otra clase denominada neutral, que consideramos negativa en la clasificación binaria y que se toma como tercera clase objetivo en caso de clasificación multiclase.

B. Proceso de diseño y análisis de tareas

primero realizamos una revisión exhaustiva de literatura sobre análisis y visualización de datos espacio-temporales de sentimientos en redes sociales.

En la primera serie de análisis, se expuso el impacto emocional por región y fase del desastre. esto se presento cómo un sistema de visual analytics podría integrar flujos de tuits, geolocalización y análisis profundo de sentimientos para dar respuesta a esos retos.

para identificar y consolidar las tareas de análisis se propuso dos módulos principales:

Módulo 1: Inspección de patrones de sentimiento — T1. ¿Cuáles son los patrones de sentimiento más frecuentes en los tuits relacionados con el desastre?

— T2. ¿Qué palabras clave semánticas los caracterizan y cómo varían según el contexto?

Módulo 2: Análisis de evolución espacio-temporal — T3. ¿Cómo evolucionan las proporciones de tuits negativos, neutrales y positivos a lo largo del tiempo?

— T4. ¿En qué zonas geográficas se concentra el mayor riesgo emocional en cada intervalo?

— T5 ¿Qué patrones de evolución emocional se repiten en fases distintas del evento?

Estas tareas guían tanto la arquitectura del sistema desde la ingestión de datos y extracción de embeddings hasta la generación de mapas de riesgo emocional— como el diseño de las interfaces de visualización que permiten explorar la dataset de forma interactiva.

IV. PIPELINE

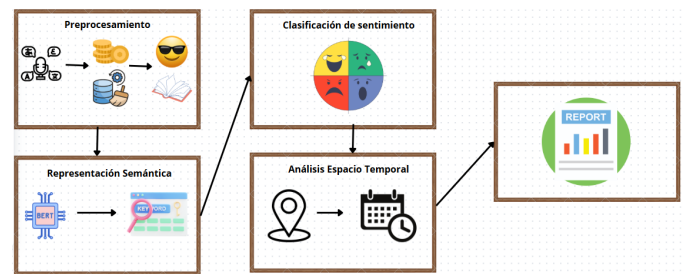


Fig. 1. Enter Caption

A. Preprocesamiento

En esta etapa, cada tweet es sometido a un proceso de limpieza y normalización. Primero se detecta automáticamente el idioma del mensaje; si no se encuentra en inglés, se aplica una traducción automática para compatibilidad con modelos

monolingües. El texto es tokenizado y se eliminan símbolos innecesarios. Asimismo, los emojis son convertidos en etiquetas semánticas, lo que permite preservar su valor emocional en el análisis posterior (por ejemplo, “(emoji)” se transforma en *sadness*, y “(emoji)” en *fire*).

B. Generación de Representación Semántica

Luego del preprocesamiento, el contenido textual es transformado en vectores de características mediante el modelo BERTweet, un modelo de lenguaje entrenado específicamente en datos de Twitter. Este modelo permite obtener embeddings contextuales que capturan el significado de cada palabra en su contexto. Posteriormente, se emplea KeyBERT, en conjunto con los pesos de atención generados por el modelo, para identificar las palabras clave más relevantes de cada tweet. Estas palabras clave son utilizadas en etapas posteriores para el análisis emocional y temático.

C. Clasificación de Sentimientos

A partir de la representación semántica del tweet completo, se realiza la clasificación emocional utilizando una red neuronal con capa softmax entrenada en un corpus etiquetado con múltiples emociones (como tristeza, miedo, ira, alivio, entre otros). El modelo devuelve la clase emocional predominante junto con un nivel de confianza. Esto permite transformar el texto en un vector emocional interpretable que puede ser analizado de forma cuantitativa.

D. Análisis Espaciotemporal

Cada tweet es asociado a una ubicación geográfica y una ventana temporal. Si la ubicación explícita no está disponible, se infiere a partir del contenido textual utilizando técnicas de geoparsing y reconocimiento de entidades. Luego, se agrupan los tweets por

V. DISEÑO DEL SISTEMA




Fig. 2. Las graficas de barras esta asociada a la distribucion de confianza en relacion con la cantidad de tweets , la grafica circular esta asociada a la categoria relevante y no relevante

En la Figura 1 se presenta un gráfico de barras que muestra la relación entre la cantidad de tweets y el nivel de confianza asignado por etiquetadores verificados y no verificados. La confianza, representada por valores entre 0 y 1, indica el grado de fiabilidad de cada tweet dentro del conjunto de

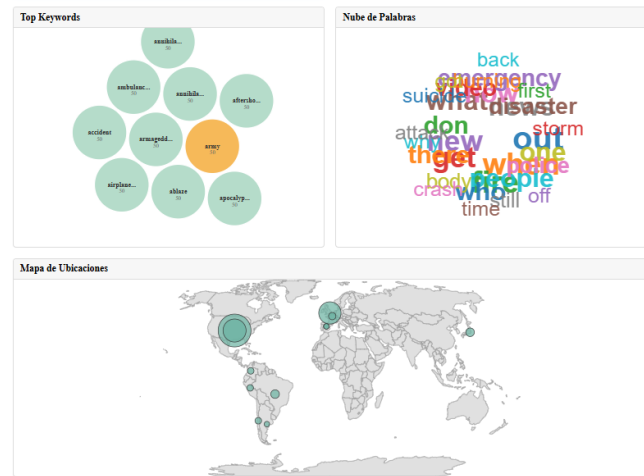


Fig. 3. Las burbujas indican las palabras clave encontradas en los tweets , la nube de palabras indica las palabras mas frecuentes de todos los tweets ,el mapa indican la ubicacion de los tweets que tienen una ubicacion asociada

datos, donde valores más cercanos a 1 reflejan mayor confianza. Adicionalmente, el gráfico circular proporciona a los expertos una visualización de la clasificación de los tweets como relevantes, no relevantes o indecisos. Este análisis es crucial para identificar y filtrar adecuadamente los tweets relacionados con desastres naturales, minimizando así el riesgo de trabajar con entradas erróneas. ¿En la Figura 2 se muestran tres visualizaciones complementarias. Primero, el gráfico de burbujas destaca las palabras clave más relevantes asociadas a cada tweet, lo cual será especialmente útil en la etapa de entrenamiento del modelo. Estas palabras están codificadas por colores según categorías como tipo de desastre, ubicación, consecuencias o entidades mencionadas. Luego, la nube de palabras ofrece una visión general de los términos más frecuentes en los tweets; al posicionar el cursor sobre cada palabra, se despliega su frecuencia de aparición. Finalmente, el mapa geográfico permite visualizar la ubicación de los tweets que contienen información de localización, lo que facilita identificar las regiones con mayor concentración de actividad en redes sociales durante eventos catastróficos.

REFERENCES

- [1] X. Zhang, Y. Li, y Z. Liu, "Public attention and emotional response after earthquakes: A comparative study of Yangbi and Maduo earthquakes using LDA and emotion lexicons," *Journal of Disaster Research*, vol. XX, no. X, pp. XX–XX, 20XX.
- [2] J. Wang, L. Chen, y M. Zhao, "Sentiment evolution and spatio-temporal dynamics of public response to the Changsha self-built house collapse," *Natural Hazards*, vol. XX, no. X, pp. XX–XX, 20XX.
- [3] H. Liu, T. Yang, y Y. Sun, "Spatio-temporal text classification for emergency response during flood disasters using Microblog data," *IEEE Access*, vol. XX, pp. XX–XX, 20XX.
- [4] R. Pérez, A. Gómez, y L. Ortega, "Big Data and sentiment analysis in tourism: A review of methods and applications," *Tourism Management Perspectives*, vol. XX, no. X, pp. XX–XX, 20XX.
- [5] M. Huang, Q. Liu, y S. Wang, "Aspect-based sentiment analysis with deep learning: A survey," *IEEE Transactions on Affective Computing*, vol. XX, no. X, pp. XX–XX, 20XX.
- [6] A. Kumari, S. Tanwar, S. Tyagi, N. Kumar, R. M. Parizi, and K. K. R. Choo, "Fog data analytics: A taxonomy and process model," *Journal of Network and Computer Applications*, vol. 128, pp. 90–104, 2019.
- [7] N. F. Ibrahim and X. Wang, "Decoding the sentiment dynamics of online retailing customers: Time series analysis of social media," *Computers in Human Behavior*, vol. 96, pp. 32–45, 2019.
- [8] A. Singh, S. Garg, S. Batra, and N. Kumar, "Probabilistic data structure-based community detection and storage scheme in online social networks," *Future Generation Computer Systems*, vol. 94, pp. 173–184, 2019.
- [9] Figure Eight, "Socialmedia-disaster-tweets-DFE," Creative Commons, dataset, ca. 6 440 tweets. Disponible en Kaggle y GitHub, 2018.
- [10] Figure Eight, "Socialmedia-disaster-tweets-DFE (GitHub)," Creative Commons, dataset, disponible en: <https://github.com/fivethirtyeight/social-media-disaster-tweets>, 2018.
- [11] MITD3M, "Socialmedia-disaster-tweets-DFE dataset information," primer baseline con XGBoost (accuracy ≈ 0.813) e información de procesamiento, 2018–2021.
- [12] A. Alfarrarjeh, S. Agrawal, S. Kim, and C. Shahabi, "Geo-Spatial Multimedia Sentiment Analysis in Disasters," in *2017 IEEE International Conference on Data Science and Advanced Analytics (DSAA)*, 2017, pp. 193–202, doi: 10.1109/DSAA.2017.77.